

# 看见什么、重建什么、想象什么： 面向视觉语言模型时空知觉的行为反演研究提纲

ordinary-bench 论文规划稿

2026 年 3 月 12 日

## 目录

|       |                  |   |
|-------|------------------|---|
| 1     | 推荐定位与边界          | 3 |
| 2     | 核心科学问题与研究假设      | 3 |
| 2.1   | 核心问题             | 3 |
| 2.2   | 研究假设             | 4 |
| 3     | 摘要提纲             | 4 |
| 3.1   | 问题动机             | 4 |
| 3.2   | 方法概述             | 4 |
| 3.3   | 预期结论             | 5 |
| 3.4   | 意义               | 5 |
| 4     | 论文整体结构           | 5 |
| 4.1   | 第 1 节：引言         | 5 |
| 4.2   | 第 2 节：相关工作       | 5 |
| 4.2.1 | VLM 的空间知觉与视觉盲点   | 5 |
| 4.2.2 | 视频理解与时间推理        | 6 |
| 4.2.3 | 选择性回答、可靠性与视觉贡献分离 | 6 |
| 4.2.4 | 从约束到场景：重建与几何理论   | 6 |
| 4.2.5 | 神经科学启发的模型分析      | 7 |

|                          |    |
|--------------------------|----|
| 目录                       | 2  |
| 4.3 第 3 节：问题定义与评测对象      | 7  |
| 4.3.1 外显场景信念             | 7  |
| 4.3.2 三类能力的区分            | 7  |
| 4.3.3 推荐写法               | 7  |
| 4.4 第 4 节：数据、任务与协议设计     | 8  |
| 4.4.1 静态场景模块             | 8  |
| 4.4.2 动态场景模块             | 8  |
| 4.4.3 四类任务族              | 8  |
| 4.4.4 三种问答协议             | 8  |
| 4.4.5 关键控制实验             | 9  |
| 4.5 第 5 节：行为反演与神经科学式分析方法 | 9  |
| 4.5.1 从回答到约束             | 9  |
| 4.5.2 从约束到场景重建           | 9  |
| 4.5.3 行为层面的“神经科学式”协议     | 9  |
| 4.5.4 可选的内部表示分析          | 10 |
| 4.6 第 6 节：实验设计与指标体系      | 10 |
| 4.6.1 实验矩阵               | 10 |
| 4.6.2 基础指标               | 10 |
| 4.6.3 人类基线               | 11 |
| 4.7 第 7 节：结果组织建议         | 11 |
| 4.7.1 主结果                | 11 |
| 4.7.2 预期结果图景             | 11 |
| 4.7.3 错误分析               | 12 |
| 4.8 第 8 节：讨论与科学解释        | 12 |
| 4.9 第 9 节：局限性与后续工作       | 12 |
| 5 图表与表格规划                | 12 |
| 5.1 推荐图                  | 12 |
| 5.2 推荐表                  | 13 |
| 6 最小可发版本建议               | 13 |

## 1 推荐定位与边界

**推荐主标题** 看见什么、重建什么、想象什么：面向视觉语言模型时空知觉的行为反演研究

**一句话摘要** 本文不把视觉语言模型 (VLM) 当作黑箱答题器来比较准确率，而是借鉴神经科学和心理物理学中的行为反演思路，把模型回答转化为可检验的时空约束，再通过场景重建、场景补全和未来想象任务，分析模型究竟从图像和视频中看见了什么、稳定保留了什么、以及无法形成何种时空表征。

**推荐主线** 第一版主文应聚焦三件事：

- 一个建立在 3D 渲染世界上的受控时空知觉评测框架；
- 一个从 VLM 行为反推出外显场景信念 (scene belief) 的重建分析框架；
- 一套区分真实视觉贡献与语言先验的控制实验。

**当前仓库的真实边界** 当前仓库最成熟的是静态空间基准、三条件控制实验、多视角输入与 2D scene belief reconstruction。动态部分已经具备可生成短视频、逐帧状态与事件标签的原型，但主链路尚未完全闭环。因此文稿中建议使用如下措辞：

- 强调 **3D-rendered controlled worlds**，而不是宣称已经完成 full 3D world model benchmark；
- 强调 **2D/2.5D** 的外显时空表征分析，而不是宣称已经恢复真实三维物理状态；
- 把动态部分写成时空扩展主实验或强补充实验，不要写成“所有模块都已 fully scaled”。

## 2 核心科学问题与研究假设

### 2.1 核心问题

- **RQ1:** VLM 的空间与时间回答中，有多少信息真正来自视觉输入，而不是语言先验或任务模板？
- **RQ2:** 当问题是人类直观且低门槛的时空判断时，VLM 是否能形成稳定、一致、可重建的场景表征？

- **RQ3:** VLM 的表征更像是局部 2D 纹理匹配，还是能够支持物体级、关系级、轨迹级的时空重构？
- **RQ4:** 在场景重绘、场景补全和未来想象任务中，VLM 暴露出的误差主要来自感知缺失、结构不一致，还是时序建模失败？
- **RQ5:** 多视角、长时间跨度、顺序打乱、时间反转等操控，会如何改变 VLM 的时空信念？

## 2.2 研究假设

- **H1:** 单题准确率会高估 VLM 的几何能力；一旦转向场景级重建，模型的真实时空表征缺陷会被放大。
- **H2:** 允许拒答、集合回答与重述一致性检查后，模型的约束质量会优于强制作答协议 [1, 2, 3].
- **H3:** 正确图像条件下的场景重建质量，应显著优于错误图像与无图像条件，否则说明模型主要依赖语言先验 [4, 5].
- **H4:** 空间关系任务中，距离排序能力会明显优于方向、顺序、速度与轨迹理解；多视角能显著缓解静态歧义，但不能自动解决时间知觉问题 [6, 7].
- **H5:** 即使 VLM 能给出局部正确答案，它仍可能无法形成单模态、低 spread 的场景信念，表现为高冲突、低可满足性和多模态解空间。

# 3 摘要提纲

## 3.1 问题动机

现有 VLM 基准普遍将视觉理解压缩为离散问答分数，难以区分“真正看见了”“依赖语言先验猜对了”“知道自己看不清”的差异。与此同时，近期工作显示，许多大模型在视觉细粒度感知、语言先验剥离和视频时序理解上仍存在系统性盲点 [6, 7, 5, 4, 8, 9, 10].

## 3.2 方法概述

本文提出一个受神经科学行为实验启发的 VLM 时空知觉评测框架：在 3D 渲染环境中生成静态场景和动态短视频，构造空间关系、时间关系、场景重绘、场景补全和未来想象任务；再将模型输出转为关系约束，通过 scene belief reconstruction 反推出模型

的外显时空表征，并用错误图像、无图像、视角变化、顺序打乱与时间反转等对照实验估计真实视觉信息增益。

### 3.3 预期结论

预期发现包括：VLM 对静态距离排序的表现显著优于方向与时序任务；多视角能改善空间感知但难以替代稳定的时间建模；在错误图像和无图像条件下，模型仍会输出具语言偏置的“伪场景信念”；场景重建指标比单题准确率更能揭示 VLM 的真实时空缺陷。

### 3.4 意义

本文的意义不在于给 VLM 再加一个 benchmark，而在于提出一种从行为反推内部时空表征的方法论，使“VLM 看到了什么”可以被操作化、量化并与生物启发的实验范式接轨。

## 4 论文整体结构

### 4.1 第 1 节：引言

引言建议按如下逻辑展开：

- 先指出大模型评测的核心缺口：我们知道它们能答题，但不知道它们是否形成了稳定的时空世界表征。
- 再指出现有视觉基准的问题：任务往往偏向识别、语言化描述或粗粒度视频 QA，缺少对空间几何、时序连续性、场景可重建性的联合分析 [6, 7, 8, 9, 10, 11].
- 接着提出本文视角：借鉴神经科学中的逆向研究思路，把模型行为视作观测信号，通过约束、重建和干预实验反演 VLM 的外显场景信念。
- 最后给出贡献列表。

### 4.2 第 2 节：相关工作

#### 4.2.1 VLM 的空间知觉与视觉盲点

这一段建议覆盖：

- 空间推理专门能力: SpatialVLM[6];
- 视觉感知与推理脱节: BLINK[7];
- 视觉评测路径本身是否合理: MMStar[5];
- 语言先验污染视觉判断: VLInd-Bench[4]。

#### 4.2.2 视频理解与时间推理

这一段建议覆盖:

- 通用视频评测: Video-MME[8];
- 长视频与多任务理解: MLVU[9];
- 专门面向时间推理的评测: TempCompass[10];
- 时间感知型模型: TimeChat[12] 与 VTimeLLM[13];
- 更接近 4D 世界理解的视角: VLM4D[11] 与 Feature4X[14]。

#### 4.2.3 选择性回答、可靠性与视觉贡献分离

这一段建议强调:

- 允许 abstain 的 VQA 可靠性 [1];
- selective VQA[2];
- 黑盒 VLM 的一致性与不确定性分析 [3]。

#### 4.2.4 从约束到场景: 重建与几何理论

这一段建议作为方法学支撑:

- ordinal embedding 与非度量嵌入 [15, 16];
- 欧氏距离矩阵与可实现性 [17];
- bearing / angle rigidity 对方向约束唯一性的解释 [18, 19]。

#### 4.2.5 神经科学启发的模型分析

这里不必把篇幅写得很重，但建议明确：

- 借用“由行为观测反推内部表征”的思想，而不是声称能直接读出模型内部语义；
- 可用 *Language Models Represent Space and Time*[20] 作为“模型内部可能形成时空结构”的背景；
- 若后续有开放权重模型，可在补充材料里加隐藏状态或表示几何分析；若没有，则主文坚持行为可检验路线。

### 4.3 第 3 节：问题定义与评测对象

#### 4.3.1 外显场景信念

建议定义：

$$B_m(I) \quad \text{或} \quad B_m(I_{1:T})$$

表示模型  $m$  对静态图像或视频输入的外显场景信念。这个对象不是隐藏向量，而是可由回答、拒答、重述一致性、集合式答案与场景重建共同反演出来的可行约束结构。

#### 4.3.2 三类能力的区分

建议把论文中的能力拆成三类：

- 感知 (perception)：模型能否从图像或视频中读出局部空间与时间关系；
- 重建 (reconstruction)：模型给出的约束能否支持稳定、低歧义的场景恢复；
- 想象 (imagination)：在遮挡、缺帧、未来时刻预测等条件下，模型能否补全潜在场景。

#### 4.3.3 推荐写法

这一节建议明确一句：

本文关注的不是 VLM 是否“会说关于空间和时间的话”，而是它是否形成了可由行为外显、可由重建检验、可由对照实验验证的时空世界模型。

## 4.4 第 4 节：数据、任务与协议设计

### 4.4.1 静态场景模块

建议以当前仓库为主：

- 在 Blender 中生成多物体场景、单视角与多视角图像；
- 使用 QRR（距离排序）和 TRR（相对钟面方向）刻画空间结构；
- 分析随物体数量上升的性能退化与可重建性变化。

### 4.4.2 动态场景模块

建议写成“动态扩展主实验”：

- 从静态对象布局扩展到 static / linear / circular 运动轨迹；
- 逐帧记录位置、速度和事件标签；
- 在论文措辞上强调由 3D 渲染环境生成的 2.5D 动态轨迹世界，避免对 full 3D dynamics 过度承诺。

### 4.4.3 四类任务族

建议把任务分为四组：

- 空间判断: QRR / TRR / 多视角空间关系；
- 时间判断: 起止关系、顺序、速度比较、轨迹类型、事件反转；
- 场景重绘与复原: 输出俯视布局、对象关系图、遮挡补全；
- 未来想象: 下一帧、终态、碰撞前后、关系翻转时刻预测。

### 4.4.4 三种问答协议

建议保留：

- forced QA: 传统强制作答；
- selective QA: 允许拒答、模糊、集合回答 [1, 2, 3]；
- direct extraction: 直接输出对象关系集合或场景图，可参考 scene graph generation 路线 [21, 22]。



#### 4.4.5 关键控制实验

建议至少写出以下干预：

- 正确图像 / 错误图像 / 无图像；
- 单视角 / 多视角；
- 单帧 / 多帧；
- 原序视频 / 打乱帧序 / 时间反转；
- 完整场景 / 局部遮挡 / 缺帧补全。

### 4.5 第 5 节：行为反演与神经科学式分析方法

#### 4.5.1 从回答到约束

建议说明：模型输出首先被转为关系观测，再归一化为 QRR、TRR、速度排序、事件顺序、轨迹类别等时空约束。

#### 4.5.2 从约束到场景重建

建议把当前仓库中的 reconstruction 写成论文方法核心之一：

- 距离约束用 ordinal embedding 视角建模 [15, 16]；
- 可实现性与几何自由度由 EDM 与 rigidity 理论解释 [17, 18, 19]；
- 输出场景级指标，而不是停留在单题分数。

#### 4.5.3 行为层面的“神经科学式”协议

这里建议把方法论写成四个词：

- **Probe**: 用重述、一致性、互逆、传递与跨条件对照，测试表征是否稳定；
- **Lesion**: 用遮挡、错图、删帧、乱序与反转，测试表征依赖于哪些视觉线索；
- **Reconstruct**: 用 scene belief reconstruction 测试这些行为能否支撑一个统一几何解释；
- **Imagine**: 用补全和未来预测测试模型是否拥有超出当前感知的时空内推能力。

4.5.4 可选的内部表示分析

如果后续只使用 API 模型，这一部分不要写成主方法，只可在讨论或补充材料中写成“未来可扩展”：

- 开放权重模型可增加层级 probe、表征相似性或时间步激活分析；
- 主文结论应坚持建立在可复现实验行为之上。

4.6 第 6 节：实验设计与指标体系

4.6.1 实验矩阵

| 模块      | 研究问题             | 关键对照                                | 核心指标                                                     |
|---------|------------------|-------------------------------------|----------------------------------------------------------|
| 静态空间知觉  | 模型能否正确读取距离与方向结构  | 单视角 vs 多视角；小场景 vs 大场景               | QRR/TRR accuracy, missing rate                           |
| 视觉贡献分离  | 视觉信息是否真正起作用      | 正确图像 vs 错误图像 vs 无图像                 | VIG, vig_tau, vision_helps_rate                          |
| 场景信念重建  | 回答能否支撑统一几何场景     | GT 约束 vs 模型约束; 强制作答 vs selective QA | CSR, NRMS, Kendall $\tau$ , $K_{\text{geom}}$ , spread   |
| 时间知觉    | 模型是否理解顺序、速度和轨迹   | 单帧 vs 多帧; 原序 vs 乱序 vs 反转            | order accuracy, velocity ranking, trajectory accuracy    |
| 场景补全与想象 | 模型是否能补全隐藏状态和未来状态 | 遮挡 vs 无遮挡; 缺帧 vs 完整输入               | completion error, future event accuracy, trajectory NRMS |

4.6.2 基础指标

建议保留当前仓库已实现的指标：

- 准确率：QRR、TRR、temporal relation、trajectory；
- 结构一致性：transitivity、reciprocity、跨重述一致性；

- 重建指标：CSR、NRMS、Kendall  $\tau$ 、 $K_{\text{geom}}$ 、spread；
- 视觉增益：正确图像相对错误图像和无图像的重建优势。

#### 4.6.3 人类基线

建议单列一个小节：

- 人类应在静态空间判断与粗粒度时间顺序上接近天花板；
- 若 VLM 在人类直观任务上仍显著失分，会强化论文的科学说服力；
- 人类基线应至少覆盖：静态空间、时间顺序、遮挡补全三类任务。

### 4.7 第 7 节：结果组织建议

#### 4.7.1 主结果

主结果建议按“从简单到复杂”的顺序组织：

1. 静态空间任务中，模型能做对哪些局部判断；
2. 场景级 reconstruction 暴露出哪些全局不一致；
3. 三条件实验显示多少能力是真正视觉驱动；
4. 动态任务中，模型在哪些时间知觉维度急剧退化；
5. 场景重绘、复原和想象任务如何进一步揭示表征边界。

#### 4.7.2 预期结果图景

建议预期如下图景：

- QRR 明显高于 TRR，静态多视角能显著提高空间关系读取；
- 在错误图像和无图像条件下，模型仍会形成语言偏置驱动的伪约束；
- 从单题准确率看似“还不错”的模型，在 scene-level reconstruction 上可能不可行、欠约束或多模态；
- 动态任务中，长时程、事件顺序与速度估计会比静态空间判断退化更快；
- 场景想象任务会揭示模型是否拥有真正的时空 continuity，而不仅是局部视觉匹配。

### 4.7.3 错误分析

建议把错误归因为三层：

- 感知层失败：根本没有读到局部几何或事件；
- 结构层失败：局部答案互相矛盾，无法形成统一场景；
- 时序层失败：知道单帧内容，但无法维持跨时间连续表征。

## 4.8 第 8 节：讨论与科学解释

讨论部分建议围绕三句话展开：

- VLM 看见了什么：更偏局部视觉线索、弱物体级几何结构，还是已经形成可重建场景；
- VLM 没看见什么：稳定的参照系、时间连续性、遮挡下的对象持久性、未来状态可预测性；
- 为什么这种分析重要：因为它把“模型是否理解时空”从口头判断变成了可重建、可对照、可统计检验的问题。

## 4.9 第 9 节：局限性与后续工作

建议坦诚写出：

- 当前动态实现更接近 2.5D，而非 full 3D 物理世界；
- 目前更强的是行为反演，不是内部神经机制解释；
- 更长视频、真实世界视频、人类基线和多摄像机动态场景是下一阶段工作。

# 5 图表与表格规划

## 5.1 推荐图

- **Figure 1**: 整体方法图。输入图像/视频 → 回答 → 约束 → 重建 → 时空信念分析。
- **Figure 2**: 正确图像、错误图像、无图像三条件下的同一场景重建对比。
- **Figure 3**: 多视角和单视角在 scene belief reconstruction 上的 spread/NRMS 分布。

- **Figure 4:** 动态任务中原序、乱序、反转的性能曲线。
- **Figure 5:** 场景重绘、遮挡补全、未来想象的可视化案例。

## 5.2 推荐表

- **Table 1:** 模型总体准确率与缺失率。
- **Table 2:** 重建指标总表 (CSR、NRMS、 $K_{\text{geom}}$ 、spread)。
- **Table 3:** 三条件视觉增益与语言先验分析。
- **Table 4:** 时间知觉结果 (顺序、速度、轨迹、事件)。
- **Table 5:** 人类与 VLM 在直观时空任务上的差距。

# 6 最小可发版本建议

## 推荐的 v1 论文组合

- 主线: 静态空间 benchmark + behavior reconstruction + three-condition visual gain;
- 强补充: 动态时间知觉小规模主实验 (顺序、速度、轨迹);
- 案例分析: 场景重绘、遮挡补全、未来想象三类可视化。

## 不建议在 v1 中过度扩展的内容

- full 3D 物理建模;
- 过重的内部激活解释;
- 过多模型训练细节;
- 过宽的真实视频 benchmark 拼盘。

**一句话结论模板** 即使在 3D 渲染的受控环境和对人类而言高度直观的时空任务中，当前 VLM 也往往只能给出局部正确、全局不稳的回答；只有将其行为转化为可重建的时空信念，我们才能真正回答“模型究竟看见了什么”。

## 参考文献

- [1] Spencer Whitehead, Vedaad Shakib, Suzanne Petryk, and Marcus Rohrbach. Reliable visual question answering: Abstain rather than answer incorrectly. *arXiv preprint arXiv:2210.07000*, 2022.
- [2] Julian Martin Eisenschlos, Hernan Maina, Guido Ivetta, and Luciana Benotti. Selectively answering visual questions. In *Findings of the Association for Computational Linguistics: ACL 2024*, 2024.
- [3] Zaid Khan and Yun Fu. Consistency and uncertainty: Identifying unreliable responses from black-box vision-language models for selective visual question answering. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.
- [4] Kang-il Lee, Minbeom Kim, Seunghyun Yoon, Minsung Kim, Dongryeol Lee, Hyukhun Koh, and Kyomin Jung. Vlind-bench: Measuring language priors in large vision-language models. In *Findings of the Association for Computational Linguistics: NAACL 2025*, 2025.
- [5] Lin Chen, Jinsong Li, Xiaoyi Dong, Pan Zhang, Yuhang Zang, Zehui Chen, Haodong Duan, Jiaqi Wang, Yu Qiao, Dahua Lin, and Feng Zhao. Are we on the right way for evaluating large vision-language models? *arXiv preprint arXiv:2403.20330*, 2024.
- [6] Boyuan Chen, Zhuo Xu, Sean Kirmani, Brian Ichter, Dorsa Sadigh, Leonidas Guibas, and Fei Xia. Spatialvlm: Endowing vision-language models with spatial reasoning capabilities. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.
- [7] Xingyu Fu, Yushi Hu, Bangzheng Li, Yu Feng, Haoyu Wang, Xudong Lin, Dan Roth, Noah A. Smith, Wei-Chiu Ma, and Ranjay Krishna. Blink: Multimodal large language models can see but not perceive. *arXiv preprint arXiv:2404.12390*, 2024.
- [8] Chaoyou Fu, Yuhan Dai, Yongdong Luo, Lei Li, Shuhuai Ren, Renrui Zhang, Zihan Wang, Chenyu Zhou, Yunhang Shen, Mengdan Zhang, Peixian Chen, Yanwei Li, Shaohui Lin, Sirui Zhao, Ke Li, Tong Xu, Xiawu Zheng, Enhong Chen, Caifeng Shan, Ran He, and Xing Sun. Video-mme: The first-ever comprehensive evaluation benchmark of multi-modal llms in video analysis. *arXiv preprint arXiv:2405.21075*, 2024.

- [9] Junjie Zhou, Yan Shu, Bo Zhao, Boya Wu, Zhengyang Liang, Shitao Xiao, Minghao Qin, Xi Yang, Yongping Xiong, Bo Zhang, Tiejun Huang, and Zheng Liu. Mlvu: Benchmarking multi-task long video understanding. *arXiv preprint arXiv:2406.04264*, 2024.
- [10] Yuanxin Liu, Shicheng Li, Yi Liu, Yuxiang Wang, Shuhuai Ren, Lei Li, Sishuo Chen, Xu Sun, and Lu Hou. Tempcompass: Do video llms really understand videos? *arXiv preprint arXiv:2403.00476*, 2024.
- [11] Shijie Zhou, Alexander Vilesov, Xuehai He, Ziyu Wan, Shuwang Zhang, Aditya Nagachandra, Di Chang, Dongdong Chen, Xin Eric Wang, and Achuta Kadambi. Vlm4d: Towards spatiotemporal awareness in vision language models. *arXiv preprint arXiv:2508.02095*, 2025.
- [12] Shuhuai Ren, Linli Yao, Shicheng Li, Xu Sun, and Lu Hou. Timechat: A time-sensitive multimodal large language model for long video understanding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024.
- [13] Bin Huang, Xin Wang, Hong Chen, Zihan Song, and Wenwu Zhu. Vtimellm: Empower llm to grasp video moments. *arXiv preprint arXiv:2311.18445*, 2024.
- [14] Shijie Zhou, Hui Ren, Yijia Weng, Shuwang Zhang, Zhen Wang, Dejia Xu, Zhiwen Fan, Suyu You, Zhangyang Wang, Leonidas Guibas, and Achuta Kadambi. Feature4x: Bridging any monocular video to 4d agentic ai with versatile gaussian feature fields. *arXiv preprint arXiv:2503.20776*, 2025.
- [15] Sameer Agarwal, Josh Wills, Lawrence Cayton, and Gert Lanckriet. Generalized non-metric multidimensional scaling. In *Proceedings of the Eleventh International Conference on Artificial Intelligence and Statistics*, 2007.
- [16] Ke Ma, Qianqian Xu, and Xiaochun Cao. Robust ordinal embedding from contaminated relative comparisons. *arXiv preprint arXiv:1812.01945*, 2018.
- [17] Ivan Dokmanić, Reza Parhizkar, Juri Ranieri, and Martin Vetterli. Euclidean distance matrices: Essential theory, algorithms, and applications. *IEEE Signal Processing Magazine*, 32(6):12–30, 2015.
- [18] Shiyu Zhao and Daniel Zelazo. Bearing rigidity theory and its applications for control and estimation of network systems: Life beyond distance rigidity. *IEEE Control Systems Magazine*, 39(2):66–83, 2019.

- [19] Yiguang Chen, Ming Cao, and Chi Li. Angle rigidity and its usage to stabilize multi-agent formations in 2-d. *IEEE Transactions on Automatic Control*, 66(11):5417–5423, 2021.
- [20] Wes Gurnee and Max Tegmark. Language models represent space and time. In *The Twelfth International Conference on Learning Representations*, 2024.
- [21] Seonghoon Kim et al. Llm4sgg: Large language model for weakly supervised scene graph generation. *arXiv preprint arXiv:2404.06974*, 2024.
- [22] Siddharth Dutta et al. Open-world scene graph generation using vision-language models. *arXiv preprint arXiv:2502.11834*, 2025.